

基于多模态融合的电诈音频检测系统

——Whisper ASR + RoBERTa + Qwen2.5 QLoRA 级联架构的设计、实现与对比分析

深度学习课程项目技术报告

项目团队

2026 年 5 月 31 日

摘要

随着电信网络诈骗犯罪日趋猖獗，传统基于规则匹配和关键词过滤的检测方法已难以应对诈骗分子不断翻新的话术和伪造技术。本文针对中文电话录音场景，提出并实现了一套完整的多模态电诈自动检测系统——TeleAntiFraud。该系统采用级联式深度学习架构，将 Whisper-small 自动语音识别、中文 RoBERTa 文本语义编码、以及 Qwen2.5-1.5B 大语言模型有机结合，沿着四条复杂度递增的技术路线——（1）提示词 + 冻结编码器 + MLP 分类头、（2）ASR 语音转写 + 冻结编码器 + MLP 分类头、（3）端到端音频编码器部分解冻训练、（4）基于 4-bit QLoRA 的 SFT 指令微调——系统地探索了从轻量级基线到可解释大模型微调的完整技术栈。

在包含 4000 条训练样本和 400 条测试样本的平衡二分类数据集上，ASR+MLP 融合方案以仅 1.6 MB 的可部署模型体积和约 5 分钟的单卡训练时间，取得了 F1=1.000、零假阳性、零假阴性的最佳综合性能，被确定为推荐部署方案。端到端部分解冻方案（F1=0.995, 338 MB）和 SFT LoRA 指令微调方案（F1=0.993, 35 MB，支持可解释检测理由生成）在更具挑战性的训练条件下同样展现了有竞争力的检测能力，并各自揭示了有意义的性能-成本权衡关系。此外，本文还构建了基于 Web 的交互式演示工作台，包含预置样例展示、音频文件上传检测和自由文本检测三种模式，验证了推荐方案在真实交互场景中的可行性，为后续的系统部署和功能扩展提供了完整的前后端基础。

关键词：电信诈骗检测；多模态融合；Whisper 语音识别；LoRA 微调；Qwen2.5；深度学习

1 引言

1.1 研究背景与问题陈述

电信网络诈骗已成为全球范围内增长最快的犯罪类型之一。据中国公安部统计，2024 年全国共破获电信网络诈骗案件 59.4 万起，涉案金额超过 400 亿元人民币，且呈现出跨境化、智能化、产业化的显著趋势 [?]。诈骗分子持续创新作案手法——从早期“猜猜我是谁”的简单冒充，到利用深度伪造（Deepfake）音频合成技术模仿亲友声音，再到构建完整的虚假投资理财、冒充公检法、虚假征信修复等复合型诈骗场景——其话术迭代速度远超传统检测手段的适应能力。

当前主流的电诈检测技术主要依赖以下三种范式：

- 黑名单与规则匹配：**基于已知诈骗号码库、URL 黑名单和正则表达式关键词（如“安全账户”“转账”“验证码”）进行拦截。优点是部署简单、延迟低，但无法应对新注册号码、变体话术和同义词替换；
- 通话元数据分析：**通过通话频次、时长、时段、呼叫转移链等行为特征进行异常检测。然而此类方法完全忽视通话内容的语义信息，漏检率高，且容易将合法的营销电话误判为诈骗；
- 人工审核与举报机制：**依赖受害者和监管人员的事后标注，效率低下，无法满足实时拦截和预警的业务需求。

近年来，深度学习在语音识别（Automatic Speech Recognition, ASR）、自然语言处理（Natural Language Processing, NLP）和多模态学习领域的突破性进展，为电诈检测提供了全新的技术范式。具体而言：Whisper 等大规模预训练 ASR 模型能够高质量地将中文通话音频转写为文本；RoBERTa 等预训练语言模型能够深层理解文本中的语义和意图；而 Qwen2.5 等大语言模型（Large Language Model, LLM）则具备指令遵循和可解释推理能力，能够在输出检测结论的同时生成判断理由。多模态融合技术进一步允许将音频的声学特征与文本的语义特征进行联合建模，充分利用两个模态的互补信息。

然而，在实际部署中，如何在有限的计算资源（如消费级 GPU 的 6 GB 显存）上，构建从原始音频到可部署检测模型的完整技术栈，并系统性地比较不同复杂度和成本的技术路线，仍是一个尚未被充分探索的问题。现有的研究大多聚焦于单一技术路线（如仅评估 ASR+ 分类器的性能），缺乏对多种方案在同一数据集、同一评估标准下的公平对比，尤其缺乏对模型规模、训练成本、推理效率和检测精度之间权衡关系的量化分析。

1.2 项目目标与核心贡献

本文的工作围绕以下核心问题展开：在消费级 GPU（NVIDIA GeForce RTX 3060 Laptop, 6 GB VRAM）的硬件约束下，如何构建一套覆盖“数据处理—模型训练—性能评估—前端演示”完整流程的多模态电诈检测系统，并系统性地回答“什么方案在精度、模型体积、训练成本和可解释性之间取得了最佳平衡？”

本文的主要贡献概括如下：

- (1) **多技术路线的系统性对比**: 在同一数据集 (4000 条训练/400 条测试) 和统一评估协议下, 设计并实现了四条复杂度递增的技术路线——提示词文本 + 冻结编码器 + MLP、ASR 转写文本 + 冻结编码器 + MLP、端到端 Whisper 编码器部分解冻、以及 Qwen2.5-1.5B QLoRA 指令微调——从 F1 分数、精确率、召回率、假阳性、假阴性、模型大小、训练时间、显存需求等八个维度进行了公平且可复现的定量对比;
- (2) **高效的级联架构设计**: 提出了 Whisper → RoBERTa → MLP 的级联流水线架构, 通过”冻结编码器离线缓存特征 + 轻量 MLP 在线训练”的分离策略, 将可部署模型控制在 1.6 MB, 在仅约 5 分钟的训练后即达到 F1=1.000 的完美检测性能, 为消费级硬件上的模型部署提供了可行的工程方案;
- (3) **显存受限下的端到端训练策略**: 针对 RTX 3060 6 GB 的显存约束, 设计了”在线 Whisper 编码器 (最后 2 层解冻) + 预缓存 ASR 文本嵌入”的混合端到端方案, 通过梯度累积、AMP 混合精度训练和分层学习率等策略, 在约 370 MB 的峰值显存占用下完成了音频特征的任务适配训练, 并定量分析了端到端训练相对于离线特征缓存方案的性能差异及其成因;
- (4) **可解释的 SFT LoRA 检测**: 基于 Qwen2.5-1.5B-Instruct 基座模型, 采用 4-bit NF4 QLoRA (rank=8, 仅训练 2.3% 参数) 在约 16,000 条二分类指令数据上进行了监督微调, 使模型不仅输出 fraud/normal 二分类标签, 还生成包含具体判断理由和置信度评分的结构化 JSON 检测报告, 在保持 F1=0.993 的同时实现了检测结果的可解释和可审计;
- (5) **完整的 Web 演示系统**: 搭建了基于 HTML/CSS/JavaScript 单页应用和 Python FastAPI 后端的交互式检测工作台, 支持预置样例一键展示、音频文件上传检测和自由文本检测三种模式, 覆盖了答辩演示和真实使用场景。

1.3 论文组织结构

本文剩余部分的组织如下: 第 2 节综述相关工作, 涵盖语音识别、多模态融合、参数高效微调和电诈检测四个领域; 第 3 节详细介绍数据集组成、数据分布特征及音频与文本的预处理流水线; 第 4 节依次阐述四条技术路线的模型架构、设计动机和超参数选择依据; 第 5 节描述前端演示系统的架构设计、功能模块和后端接口; 第 6 节系统呈现实验结果, 包括训练曲线、每 epoch 详细指标、综合对比与深入分析; 第 7 节围绕实验结果展开讨论, 分析各方案的适用场景与局限性; 第 8 节展望模型在数据、模型、部署和可解释性四个维度的未来优化方向; 第 9 节总结全文并给出推荐部署方案。

2 相关工作

本节从自动语音识别、多模态融合、参数高效微调和电诈检测四个角度综述与本文密切相关的现有工作, 明确本文工作的定位和创新点。

2.1 自动语音识别

自动语音识别 (ASR) 是将音频信号转换为文本序列的核心技术。近年来, 基于 Transformer 架构的大规模预训练 ASR 模型取得了显著突破。OpenAI 提出的 Whisper 系列模型 [?] 在大规模弱监督数据 (680,000 小时多语言语料) 上训练, 覆盖 99 种语言, 其中 Whisper-small 版本仅 88.2M 参数, 在中文识别任务上表现出良好的精度与效率平衡。相较于传统的 DeepSpeech 或 Conformer 模型, Whisper 的优势在于: (1) 基于 Encoder-Decoder 架构, encoder 可独立提取音频特征; (2) 原生支持中文等多语言转写; (3) 模型尺寸从 tiny (39M) 到 large (1.5B) 形成完整谱系, 允许根据硬件约束灵活选择。

本文选择 Whisper-small 作为 ASR 引擎, 在离线特征缓存阶段冻结 encoder 以提取音频嵌入, 在 ASR 转写阶段使用完整的 encoder-decoder 进行中文转录。此外, 我们将音频统一重采样至 16 kHz 并转换为 80 维 log-Mel 频谱图作为模型输入, 这是 Whisper 模型家族的标准预处理流程。

2.2 多模态融合方法

多模态融合是机器学习领域的长期研究课题。Baltrušaitis 等 [?] 将多模态融合策略分为早期融合 (特征级拼接)、中期融合 (跨模态注意力) 和晚期融合 (决策级集成) 三大类。在音频-文本联合建模中, Audio-Text Fusion 的主流范式是将音频编码器的池化嵌入与文本编码器的句嵌入进行拼接, 送入浅层分类器。

本文采用的融合策略属于早期融合：将 Whisper encoder 的 768 维音频嵌入（沿时间维度均值池化）与 RoBERTa 的 768 维文本 [CLS] 嵌入直接拼接为 1536 维向量，经 LayerNorm 归一化后送入 MLP 分类器。我们保留了中期融合（如跨模态注意力）和晚期融合（如两个单模态分类器的集成）的扩展可能性，但在当前数据规模下，简单的早期融合已展现出足够的表征能力。

2.3 参数高效微调

大语言模型的参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）是实现消费级硬件上大模型适配的关键技术。Hu 等 [?] 提出的低秩适配（Low-Rank Adaptation, LoRA）通过在预训练权重矩阵旁插入低秩分解矩阵，仅训练新增的少量参数（通常 < 基座参数的 1%），即可在下游任务上接近全量微调的性能。Dettmers 等 [?] 进一步提出了 QLoRA，将基座模型量化为 4-bit NormalFloat4 (NF4) 并结合双重量化（Double Quantization）和分页优化器（Paged Optimizer），将 65B 参数模型的微调显存需求降至单张 48 GB GPU。

本文在方案四的 SFT LoRA 微调中采用了 QLoRA 技术栈：4-bit NF4 量化 + 双重量化 + LoRA (rank=8, alpha=16) + Paged AdamW 8-bit 优化器，使 1.5B 参数的 Qwen2.5 模型能够在 RTX 3060 (6 GB) 上完成约 6.5 小时的微调。这是本文在工程层面的一项重要适配工作。

2.4 电信诈骗检测

电诈检测是一个具有重要社会价值的应用研究领域。传统方法主要依赖呼叫详单 (CDR) 分析和声纹比对，属于信号处理和模式识别的范畴。近年来，深度学习方法逐步被引入，包括：基于 LSTM/GRU 的通话文本分类、基于 BERT 的诈骗话术语义检测、基于图神经网络的诈骗团伙识别等。在音频-文本联合检测方面，Chen 等 [?] 综述了从特征工程到端到端深度学习的技术演进路径。

与现有工作相比，本文的定位在于：（1）聚焦中文电话录音这一特定场景；（2）在同一数据集和硬件约束下系统对比了四条技术路线；（3）覆盖了从 1.6 MB 轻量 MLP 到 1.5B LLM 的全频谱方案；（4）提供了完整的前端演示系统。

3 数据集与预处理

3.1 数据来源与总体规模

本研究所使用的 TeleAntiFraud 数据集来源于 HuggingFace Datasets 开源平台，是一个面向电信诈骗检测研究与教学的多模态中文数据集。数据集包含音频文件（MP3 格式的通话录音）、结构化标注（JSON/JSONL 格式的对话文本与标签）以及指令微调数据，按任务类型划分为二分类和 SFT 两个子集。

表 1: 数据集总体统计

数据集	样本数	正样本 (fraud)	负样本 (normal)	格式
二分类训练集	4,000	~2,000	~2,000	JSON
二分类测试集	400	~200	~200	JSON
SFT 训练集	27,146	—	—	JSONL
SFT 测试集	6,807	—	—	JSONL

每条二分类样本由以下字段组成：**audios**（指向 MP3 音频文件的相对路径）、**messages**（包含 system prompt 和 user text 的对话列表，在提示词方案中作为文本编码器输入）、**answers**（取值为 "normal" 或 "fraud" 的标签字符串）。

SFT 数据集采用多轮对话格式组织，按任务复杂度分为三种模式：

表 2: SFT 数据集任务模式分布

任务模式	对话轮数	样本数	说明
SCENE_ONLY	2 轮	10,711	仅识别通话场景类型，不含欺诈判断
FRAUD_BINARY	2-4 轮	10,711	二分类欺诈检测 (fraud/normal)
FRAUD_TYPE	5+ 轮	5,724	细粒度诈骗类型识别 (冒充公检法、贷款诈骗等)

三种模式中，仅 FRAUD_BINARY 包含可直接用于二分类评估的标签。从 FRAUD_BINARY 中进一步筛选后，得到可用于 LoRA 微调的二分类样本约 16,435 条，其中 fraud 约占 69.7%，normal 约占 30.3%，存在较明显的类别不平衡。这一不平衡在 SFT LoRA 训练中通过指令模板中的均衡采样策略得到部分缓解，但在评估时仍可能在正常通话样本上导致指标波动，需在结果分析中加以关注。

3.2 音频文件特征与预处理流水线

原始音频文件为 MP3 编码格式，采样率从 8 kHz 到 44.1 kHz 不等，比特率分布在 32–320 kbps 范围，单条音频时长从数秒到数分钟。预处理流水线包含以下步骤：

步骤 1：音频解码。由于 torchaudio 2.6.0 在 Windows 环境下缺少 MP3 解码后端（该问题在 Linux/macOS 下因系统级编解码器支持通常不出现），我们实现了基于 FFmpeg 的命令行回退解码方案。具体而言，当 torchaudio 加载 MP3 失败时，WhisperAudioEncoder 自动调用系统安装的 FFmpeg 二进制文件（通过 `winget install ffmpeg` 在 Windows 上安装），执行以下等效命令：

```
ffmpeg -i <input.mp3> -f s16le -acodec pcm_s16le -ar 16000 -ac 1 -
```

将任意格式音频统一解码为 16 kHz 单声道 16-bit PCM 原始数据流，再归一化至 $[-1.0, 1.0]$ 浮点范围。

步骤 2：声学特征提取。使用 Whisper 模型自带的 log-Mel 滤波器组将 16 kHz 单声道波形转换为 80 维 log-Mel 频谱图。Mel 频率刻度模拟了人耳对音高的非线性感知特性，是语音识别和音频分类任务中广泛使用的手工特征。

步骤 3：长度对齐。Whisper 编码器要求输入序列固定为 3000 帧。短于 3000 帧的音频在末尾用零值填充（zero-padding），长于 3000 帧的音频截断尾部。这一填充/截断策略的选择基于以下考量：电诈的关键信息（如威胁性语句、转账指令）通常出现在通话的中后段，因此截断尾部可能丢失部分关键信息。然而，在数据驱动的实际中，超过 30 秒的样本在数据集中占比不足 5%，且绝大多数关键语义在通话的前 30 秒内已经开始呈现。因此我们设定 `--max-audio-seconds 30` 作为上限。

3.3 文本分支的三种输入模式

文本分支的输入内容取决于具体的技术路线：

- (1) **提示词模式（方案一）：**直接使用 JSON 数据中 `messages` 字段的提示词文本作为 RoBERTa 的输入。该文本为固定的任务描述（如“请判断以下通话是否为诈骗”），不包含实际通话内容，因此文本分支仅提供与标签相关的先验任务信息；
- (2) **ASR 转写模式（方案二、三、四）：**使用 Whisper-small 的 encoder-decoder 完整模型对音频进行中文转写，将转写得到的通话文本作为 RoBERTa（方案二）或 Qwen2.5（方案四）的输入。典型转写质量示例：

- 正常通话：“您好，这里是快递员，您的包裹已经放到门口，方便时请查收。”
- 诈骗通话：“你的银行卡涉嫌异常交易，请马上把资金转入安全账户配合核查。”

可以看到，ASR 转写能够准确捕获通话的中文语义内容，为后续文本编码器提供高质量的通话级语义特征。在约 5% 的样本中，因背景噪声、多人同时说话或方言口音导致转写存在少量错字或漏字，但经验表明这些噪声并未显著影响下游分类性能；

- (3) **指令模板模式（方案四）：**将 ASR 转写文本嵌入到预定义的结构化指令模板中（详见第 4.4 节），格式化为 Qwen2.5 的对话消息列表，作为 LLM 的输入。

3.4 数据集可视化分析

为进一步理解数据的内在特征，我们从标签分布、音频时长、文本长度和关键词分布等维度对训练集进行了系统的可视化分析。




图 1: 二分类训练集标签分布: fraud 与 normal 各 2000 条, 完全均衡

图 1 确认了训练集类别完全平衡 (1:1), 这消除了因类别不平衡导致模型偏向多数的顾虑。结合测试集同样保持约 1:1 的比例, 评估指标的可靠性得到了数据集设计的保障。





图 2: 训练集音频时长分析: 直方图叠加 (左) 与箱线图 (右)

图 2 从时长维度揭示了两个类别之间的系统性差异: 正常通话平均时长 44.4 秒 (中位数 43.8 秒, 范围 12.9–93.4 秒), 诈骗通话平均时长 53.2 秒 (中位数 53.0 秒, 范围 9.8–162.8 秒)。诈骗通话的平均时长比正常通话长约 20% (8.8 秒), 且分布更广、右尾更长。这一差异的可能原因是: 诈骗分子需要更长的对话时间来建立信任、编造虚假情境并逐步引导受害者配合, 而正常的生活通知类通话 (快递、外卖、预约确认) 通常在 30–50 秒内即可完成。在模型层面, 较长的音频意味着更多的 mel 频谱帧和更丰富的声学特征, 这可能是模型对诈骗样本有较高检出率的一个有利因素。



(a) 提示词文本长度分布

(b) ASR 转写文本长度分布

图 3: 文本长度分析: (a) 提示词文本——fraud 与 normal 样本分布几乎完全重叠; (b) ASR 转写文本——fraud 样本 (均值约 180 字符) 系统性长于 normal 样本 (均值约 140 字符)

图 3 的对比呈现了一个关键发现：(a) 提示词文本的长度分布在 fraud 和 normal 类别之间几乎完全重叠——这是因为提示词文本是固定的任务描述模板，不包含真实通话语义，其长度差异仅来源于少量格式变化；(b) ASR 转写文本的长度呈现类别间系统性差异——fraud 样本平均约 180 字符，normal 样本平均约 140 字符，相差约 29%。这一定量证据直接支持了方案二的设计动机：ASR 转写文本携带了与类别相关的区分性语义信息，而提示词文本基本不包含此类信息。




图 4: 电诈关键词在 ASR 转写文本中的出现频率（按 fraud/normal 类别分组）。”转账””安全账户””验证码””银行卡””密码”等词汇在 fraud 样本中的出现频率数倍于 normal 样本，构成了模型区分两类通话的核心语义线索


图 4 以分组柱状图的形式量化了 15 个高频电诈关键词在两类样本中的出现频率差异。最突出的差异词包括”资金”（fraud 中出现约 1800 次 vs. normal 约 200 次，9 倍差异）、”账户”（约 1600 vs. 600，2.7 倍）、”转账”（约 750 vs. 50，15 倍）、”密码”（约 400 vs. 30，13 倍）以及”验证码”（约 350 vs. 20，17.5 倍）。这些关键词构成了电诈话术的”语义特征”：诈骗分子反复使用”安全账户””资金核查””转账””密码””验证码”等短语来构建虚假的紧迫性和权威性，而正常的快递、外卖通知中极少出现这些术语。相比之下，一些中性关键词如”配合””信用””确认”在两类样本中的频率差异较小，说明单独依赖这些词汇容易产生误判。从模型解释性的角度看，图 4 为基于 ASR 文本的检测方案提供了可解释的词汇级证据——模型的分类决策在很大程度上依赖于这些高频区分性关键词的识别。

4 模型架构与参数选择

本项目沿着复杂度递增的路径，依次实现了四条技术路线。各方案之间的关系可以理解为：方案一（提示词 + MLP）建立最轻量的基线；方案二（ASR + MLP）在方案一的基础上将文本来源从人工提示词替换为真实 ASR 转写，以衡量通话语义信息带来的增益；方案三（端到端部分解冻）在方案二的基础上解冻音频编码器的最后 2 层，探索音频特征任务适配的收益与成本；方案四（SFT LoRA）则将整个检测框架升级为大语言模型指令微调范式，以期在检测精度之外获得可解释的推理能力。

图 5 从宏观视角展示了覆盖全部四条路线的系统架构。

System Architecture: Whisper ASR + Qwen2.5 QLoRA Cascaded Pipeline



Training config: batch_size=1, grad_accum=8, lr=2e-4, cosine schedule, paged_adamw_8bit

图 5: 系统级架构：Whisper ASR → 文本编码 → 融合/推理 → 结构化输出的级联流水线

4.1 方案一：提示词 + 冻结编码器 + MLP 分类头

4.1.1 设计动机

方案一是整个技术栈的起点，其核心设计理念是”最大化预训练知识的复用，最小化可训练参数”。具体而言，我们冻结 Whisper-small 和 Chinese RoBERTa 的全部参数，将它们视为固定的特征提取器，仅训练一个极轻量的 MLP 融合分类头。这一方案的优势是多方面的：

- (1) **特征可离线缓存**：冻结的编码器仅需对每条样本推理一次，其输出（768 维音频嵌入 + 768 维文本嵌入）可保存为 .pt 文件。后续训练和超参数搜索完全基于缓存特征进行，无需重复加载编码器模型；
- (2) **极低的训练成本**：可训练参数仅约 0.4M (≈ 1.6 MB 存储)，在 RTX 3060 上 batch_size=64 训练 20 个 epoch 仅需约 5 分钟；
- (3) **便于超参数搜索**：相比于端到端训练，基于缓存特征的训练速度快两个数量级以上，可以方便地尝试不同的学习率、隐藏维度和 dropout 设置。

4.1.2 模型结构

音频编码器选用 OpenAI 的 Whisper-small 模型（88.2M 参数，12 层 Transformer encoder，每层 hidden_size=768）。音频经 Whisper encoder 处理后得到形状为 $(B, 3000, 768)$ 的 hidden state 序列，沿时间维度取均值池化得到 $(B, 768)$ 的音频嵌入向量。

文本编码器选用哈工大讯飞联合发布的 Chinese RoBERTa-wwm-ext (hfl/chinese-roberta-wwm-ext, 102M 参数，12 层 Transformer，hidden_size=768)。文本经 RoBERTa 处理后取 [CLS] token 的最后一层 hidden state 作为 $(B, 768)$ 的文本嵌入向量。

融合分类器将上述两个 768 维向量沿特征维度拼接为 $(B, 1536)$ 维融合特征，经以下前馈网络进行二分类：

$$\text{LayerNorm}(1536) \rightarrow \text{Linear}(1536, 256) \rightarrow \text{GELU} \rightarrow \text{Dropout}(p = 0.2) \rightarrow \text{Linear}(256, 2)$$

设计要点说明：

- **LayerNorm 前置**：在特征拼接后立即进行层归一化，消除音频嵌入和文本嵌入在数值尺度上可能存在的差异，防止某一模态主导梯度更新；
- **GELU 激活函数**：相比于 ReLU，GELU 在零点附近更平滑，在 Transformer 类模型中广泛使用，与 Whisper 和 RoBERTa 的激活函数风格一致；
- **Dropout 0.2**：适中的 dropout 率在 4000 条训练样本上提供了有效的正则化，防止 MLP 对训练集特定模式的过拟合；
- **隐藏维度 256**： $1536 \rightarrow 256 \rightarrow 2$ 的维度压缩比约为 6:1，在保留足够非线性表达能力的同时控制参数量。

4.1.3 训练超参数

表 3: 方案一/二 MLP 训练超参数

超参数	取值	选择依据
优化器	AdamW	带权重衰减的 Adam，标准选择
学习率	1×10^{-3}	小模型 + 大 batch 允许较高学习率
权重衰减	1×10^{-2}	AdamW 默认值
Batch size	64	充分利用 4000 条训练的批量统计信息
最大 Epoch	20	留出充足余量观察收敛与过拟合
学习率调度	无（恒定）	小模型在 20 epoch 内无需衰减
隐藏维度	256	1536:256:2 的合理压缩比
Dropout	0.2	标准正则化强度
梯度裁剪	max_norm=1.0	防止单批次梯度爆炸

4.2 方案二：ASR 转写 + 冻结编码器 + MLP 分类头

4.2.1 设计动机

方案一的关键局限在于：文本编码器接收的是 JSON 中固定的提示词文本（如 system prompt 中的任务描述），而非通话的真实语义内容。这使得文本分支只能提供与任务标签相关的先验偏置，而无法利用通话的实际语义信息区分正常通话与诈骗通话。

方案二的改进思路直观而关键：先用 Whisper 对音频进行中文语音转写，再将 ASR 转写文本替换提示词文本送入 RoBERTa 编码器。这一替换使文本分支从“任务描述读取器”转变为“通话语义理解器”，大幅增强了文本分支的信息含量。另外，由于仅替换了文本来源而保持模型结构和训练超参数完全不变，方案一与方案二的性能差异可以精确归因于 ASR 转写带来的语义信息增益。

4.2.2 ASR 转写实现

ASR 转写在特征缓存阶段完成。Whisper-small 的 encoder 先对音频提取声学特征，decoder 以自回归方式逐 token 生成中文文本。为控制生成质量与效率，设定以下参数：

- language="zh": 指定目标语言为中文；
- task="transcribe": 执行语音转写（而非翻译）；
- max_length=448: 生成 token 数上限（对应约 300–400 个中文字符）；
- do_sample=False: 使用贪婪解码以保证确定性输出。

转写结果以字符串形式存入特征缓存文件（.pt），在文本编码器推理时加载并进行 tokenization。

4.3 方案三：端到端部分解冻训练

4.3.1 设计动机

方案一和方案二将音频编码器完全冻结，Whisper 提取的音频特征是基于大规模通用语音识别任务预训练的，未必能最优地捕获电诈检测任务中关键的声学线索——如说话人的紧迫语气、威胁性语调、异常的语速变化等。方案三的核心动机是在显存允许的前提下，适度解冻音频编码器的高层，让音频特征在训练过程中向电诈检测任务自适应地调整。

4.3.2 混合端到端架构

直接的端到端训练需要在同一批次中同时加载 Whisper encoder（176 MB fp16）、RoBERTa（~400 MB fp16）、两者的梯度与优化器状态以及批次数据。这一组合在 RTX 3060（6 GB）上超出了可用显存。

因此，我们设计了一种“混合”端到端方案：保留方案二中已缓存的 ASR 文本 RoBERTa 嵌入作为文本分支的输入（即文本分支退化为预计算特征的直接读取，跳过 RoBERTa 的在线加载），音频分支则在线加载 Whisper encoder 并对其最后 2 层进行训练。具体架构如下：

- 音频分支：Whisper-small encoder 全部在线加载，但仅最后 2 层（layers 10–11，共约 14.2M 参数）设为可训练，前 10 层（layers 0–9）及其他非层参数（位置编码、embedding 等）保持冻结。训练时，输入音频 batch 流经冻结层（无梯度计算），在解冻层产生梯度并反向传播；
- 文本分支：直接从 .pt 缓存文件读取预计算的 768 维 ASR 文本嵌入，训练过程中不加载 RoBERTa 模型，节省约 400 MB 显存；
- 融合分类头：结构与方案一/二完全相同，全部可训练。

这一混合设计将端到端训练的峰值显存控制在约 370 MB，仅为 6 GB 总显存的 6.2%。

4.3.3 显存预算分析

表 4: 端到端训练显存预算 (fp16 混合精度)

组件	估算显存	计算方式
Whisper encoder 推理 (fp16 参数)	176 MB	$88.2\text{M} \times 2 \text{ bytes}$
最后 2 层梯度	28 MB	$14.2\text{M} \times 2 \text{ bytes}$
最后 2 层 AdamW 状态	56 MB	$14.2\text{M} \times 4 \text{ bytes (momentum + variance)}$
最后一层优化器状态	84 MB	含其他可训练参数
音频 mel 特征 (batch=1)	24 MB	$1 \times 80 \times 3000 \times 2 \text{ bytes}$
MLP 头参数 + 梯度 + 状态	~2 MB	$0.4\text{M} \times (2+2+4) \text{ bytes}$
文本嵌入 (batch=1)	<1 MB	$1 \times 768 \times 2 \text{ bytes}$
合计	~370 MB	占总显存的 6.2%

4.3.4 训练策略与 Layer Unfreezing

为在小批量下稳定训练，方案三采用以下策略组合：

- **梯度累积**：物理 `batch_size=1`，累积 8 步后执行一次 `optimizer.step()`，等效 `batch_size=8`。每次 backward 前将 `loss` 除以 8；
- **AMP 混合精度**：使用 `torch.amp.autocast("cuda")` 在前向传播中自动将计算密集型操作转为 fp16，同时配合 `torch.amp.GradScaler` 防止 fp16 下的小梯度下溢；
- **分层学习率**：MLP 融合头使用 $\text{lr}=5 \times 10^{-5}$ ，Whisper 解冻层使用 $\text{lr}=5 \times 10^{-6}$ （降低 10 倍）。这一设计的依据是：预训练的 Whisper 权重已经处于良好的局部最优附近，大幅扰动可能破坏底层学到的通用声学特征，因此解冻层仅需小幅调整；
- **梯度裁剪**：`max_grad_norm=1.0`，防止梯度累积导致的偶发梯度尖峰。

Layer Unfreezing 的实现采用了基于层索引的筛选策略：遍历 Whisper encoder 的所有 `layers` 属性，将前 `len(layers) - num_unfreeze` 层的所有参数的 `requires_grad` 设为 `False`，其余层保持默认的 `True`。此外，所有不以 `"layers."` 开头的参数（如 `embed_positions`、`conv1`、`conv2` 等）也显式设为 `False`，确保只有选定的 encoder layers 参与训练。

4.4 方案四：SFT LoRA 指令微调

4.4.1 设计动机与范式转换

前三种方案的共同特点是：模型仅输出 `normal` 或 `fraud` 的二分类标签，检测过程是一个”黑箱”——用户无法得知模型为什么做出该判断，这在需要人工复核和监管审计的实际业务场景中构成了信任障碍。

方案四引入了范式转换：从”分类器输出标签”转变为”LLM 生成结构化检测报告”。具体而言，我们利用 Qwen2.5-1.5B-Instruct 模型的指令遵循和文本生成能力，要求模型在给定通话文本后输出包含三个字段的 JSON 对象：`is_fraud`（布尔值，是否为诈骗）、`reason`（字符串，判断理由的自然语言描述）、`confidence`（浮点数，0-1 置信度评分）。

这一范式转换的代价是模型体积和推理成本的显著增加（35 MB LoRA 适配器 + 1.5B 基座模型），但其获得的”可解释性”在以下场景中具有不可替代的价值：人工审核员可快速理解模型判断逻辑、监管机构可审计模型的决策依据、用户可获得”为什么拦截这通电话”的可信解释。

4.4.2 指令模板设计

指令模板的设计遵循”角色定义—任务说明—输出格式—输入数据”的结构化 prompt 工程范式：

[SYSTEM]
你是一个专业的电信诈骗检测助手。请根据以下通话文本，
判断该通话是否为诈骗电话。请以JSON格式回复，包含以下字段：
- `is_fraud`: `true`或`false`，表示是否为诈骗电话

- **reason**: 判断理由（用中文简要说明）
- **confidence**: 0到1之间的置信度

[USER]
通话文本: {transcription}

[ASSISTANT]

在训练阶段，assistant 的回复使用数据集中的 **answers** 字段构造标准的 JSON 响应。在损失计算中，system 和 user 消息对应的 token 被屏蔽（标签设为 -100），loss 仅计算 assistant 回复部分的 token，确保模型学习的是”如何回答”而非”如何提问”。

4.4.3 QLoRA 配置与参数选择

为在 6 GB 显存约束下微调 1.5B 参数的 Qwen2.5 模型，方案四全面采用了 QLoRA 技术栈：

表 5: 方案四 QLoRA 微调超参数配置

超参数	取值	选择依据
基座模型	Qwen2.5-1.5B-Instruct	1.5B 是在 6 GB 下可运行的最大指令模型之一
量化精度	4-bit NF4	QLoRA 标准设置，4-bit 量化平衡精度与显存
双重量化	启用	进一步压缩量化常数，节省约 0.4 GB 显存
计算精度	fp16 (forward/backward)	与 GPU 架构匹配的计算精度
LoRA rank	8	常用起步值，平衡可训练容量与过拟合风险
LoRA alpha	16	alpha=2×rank 是 QLoRA 论文推荐的缩放方案
LoRA dropout	0.05	适中的正则化强度
目标模块	q_proj, k_proj, v_proj, o_proj	仅适配注意力投影层，不触碰 FFN
训练 epochs	3	27k 样本下 3 epochs 约 8 万步，loss 收敛充分
学习率	2×10^{-4}	QLoRA 推荐的起步学习率
学习率调度	Cosine annealing	从初始值平滑衰减至接近 0
优化器	Paged AdamW 8-bit	QLoRA 推荐，分页管理避免显存碎片
Batch size (物理)	1	单条序列即占约 1 GB 中间激活
梯度累积步数	8	等效 batch=8，模拟更大批量的梯度估计
最大序列长度	1024 tokens	覆盖绝大多数 ASR 转写 + 指令模板的全部 token
可训练参数量	~35M	占基座模型 1.5B 参数的约 2.3%
Adapter 存储大小	~35 MB	仅保存 LoRA 权重，不含基座模型
训练总时间	~6.5 小时	RTX 3060 Laptop, 3 epochs

4.4.4 训练过程中的关键技术点

- (1) **损失掩码 (Loss Masking)**: 训练时仅对 assistant 回复部分的 token 计算交叉熵损失。具体做法是：将 input_ids 复制为 labels，然后将 system 和 user 消息对应位置设为 -100（PyTorch CrossEntropyLoss 的 ignore_index），确保模型专注于学习”给定通话文本，如何生成准确的检测 JSON”；
- (2) **梯度检查点 (Gradient Checkpointing)**: 启用 transformers 内置的 gradient checkpointing，在前向传播中丢弃中间激活，反向传播时重新计算，以时间换空间，进一步压缩训练显存；
- (3) **评估阶段的生成式推理**: SFT 完成后，在测试集上使用 model.generate() 进行推理,do_sample=False（贪婪解码）确保确定性输出。生成的文本经正则表达式提取 JSON 中的 is_fraud 字段，与真实标签比较计算 Precision/Recall/F1。无法正确解析 JSON 的样本计入 parse_failures 指标。

表 6: 四种方案关键特征对比总览

特征维度	方案一	方案二	方案三	方案四
音频编码器	Whisper-small	Whisper-small	Whisper-small	Whisper-small
音频训练方式	冻结 + 缓存	冻结 + 缓存	最后 2 层解冻	冻结 (仅 ASR)
文本编码器	RoBERTa	RoBERTa	RoBERTa(缓存)	Qwen2.5-1.5B
文本训练方式	冻结 + 缓存	冻结 + 缓存	冻结 (预缓存)	QLoRA LoRA
文本输入来源	提示词	ASR 转写	ASR 转写	ASR 转写
分类器	MLP 0.4M	MLP 0.4M	MLP 0.4M+Enc	LLM head
输出格式	二分类标签	二分类标签	二分类标签	JSON(含理由)
可训练参数	~0.4M	~0.4M	~14.6M	~35M
模型文件大小	1.6 MB	1.6 MB	338 MB	35 MB
训练时间	~5 min	~5 min	~3 h	~6.5 h
显存需求	<1 GB	<1 GB	~2 GB	~4.5 GB

5 前端演示系统

为支持课程答辩的现场展示和系统的实际可用性验证，我们设计并实现了一个完整的 Web 交互式检测工作台。

5.1 系统架构

演示系统采用经典的”前端 SPA + 后端 API”分离架构：

- **前端：**纯静态 HTML/CSS/JavaScript 单页应用（SPA）。无任何前端框架依赖（零 npm 包），仅通过标准 Web API（Fetch API、DOM API、CSS Custom Properties）实现全部交互逻辑。这一设计确保了在任何现代浏览器中的零配置运行；
- **后端：**基于 Python FastAPI 的轻量级 HTTP 服务器（scripts/serve_demo.py）。使用 uvicorn 作为 ASGI 服务器，默认监听 http://127.0.0.1:8000；
- **静态文件服务：**HTML、CSS、JavaScript 和 favicon 通过 FastAPI 的 StaticFiles 中间件直接从 web/demo/ 目录挂载，无需单独的 Web 服务器。

5.2 前端功能模块

- (1) **预置样例标签页（答辩主路径）：**这是推荐在答辩现场使用的主要演示路径。系统预置了 3 个经过验证的典型样例——1 个正常通话样例（快递通知）和 2 个诈骗通话样例（冒充官方机构、账户风险诈骗）。每个样例均从 HuggingFace 数据集的 preview/ 目录加载音频文件，并预设了确定性的检测结果（包括 prediction、fraud_probability、risk_level、ASR 转写文本和 evidence 证据列表）。这一确定性设计确保了答辩演示在任何网络条件下都能稳定复现预期效果；
- (2) **上传检测标签页：**允许用户从本地文件系统选择 MP3 或 WAV 格式的音频文件。前端通过 <input type="file"> 接收文件，使用 FormData API 以 multipart/form-data 格式上传至后端。后端接收到音频文件后，依次执行：ASR 转写 → RoBERTa 文本编码 → MLP 融合分类推理，返回包含 prediction、fraud_probability、risk_level 和 asr_text 的 JSON 响应。此模式为备用演示路径，依赖于本地 GPU 推理；
- (3) **文本检测标签页：**提供一个 <textarea> 输入框和检测按钮，允许用户直接输入通话文本或 ASR 转写结果。后端使用基于关键词匹配的启发式评分算法进行轻量级检测——如果文本中包含预定义的诈骗关键词（”安全账户””转账””验证码””银行卡””冻结””涉嫌””公检法””贷款””中奖”），则按匹配关键词数量线性叠加概率分数（起始 0.72，每个匹配关键词 +0.08，上限 0.98）；若无关键词匹配，则判定为 normal（概率固定 0.18）。此模式无需 GPU，可作为离线和低资源场景的快速方案。

5.3 检测结果展示

无论通过哪种模式触发检测，结果面板均展示以下结构化信息：

- **模型名称:** 当前使用的检测模型标识 (“Whisper-small ASR + Chinese RoBERTa + MLP Fusion Classifier”);
- **预测标签:** normal (绿色标识) 或 fraud (红色标识);
- **欺诈概率:** 0–1 之间的数值, 格式化为 3 位小数;
- **风险等级:** low (概率 < 0.3)、medium (0.3–0.75)、high (> 0.75);
- **ASR 转写文本:** 音频的 Whisper 中文转写结果, 供用户交叉验证检测结论;
- **判断依据:** 以标签列表形式展示模型判定为 fraud/normal 的具体证据 (如” 银行卡涉嫌异常”” 转入安全账户”” 紧急核查话术” 等)。

5.4 后端 API 设计

如表 7 所示, 后端提供三个 RESTful API 端点。所有端点均返回 JSON 格式的响应, 并包含适当的 HTTP 状态码 (200 成功、404 未找到、500 服务器错误)。

表 7: 后端 API 端点

端点	方法	功能	响应内容
/api/samples	GET	获取预置样例列表	样例 ID、标题、预期标签、描述、音频 URL
/api/predict/sample/{id}	POST	对指定预置样例执行检测	prediction、 fraud_probability、risk_level、 asr_text、evidence
/api/predict/text	POST	对文本输入执行启发式检测	prediction、 fraud_probability、risk_level、 evidence、mode

6 实验结果与性能对比

6.1 评估协议

所有方案统一在 400 条二分类测试样本 (正负样本约各 200 条) 上评估。评估指标包括:

- **准确率 (Accuracy):** $\frac{TP+TN}{TP+TN+FP+FN}$, 衡量整体分类正确率;
- **精确率 (Precision):** $\frac{TP}{TP+FP}$, 衡量” 被判为诈骗的样本中有多少是真正的诈骗”;
- **召回率 (Recall):** $\frac{TP}{TP+FN}$, 衡量” 真正的诈骗样本中有多少被正确检出”;
- **F1 分数:** $\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$, 精确率与召回率的调和平均;
- **假阳性 (FP):** 被误判为诈骗的正常通话数;
- **假阴性 (FN):** 被漏判为正常的诈骗通话数。

在上述指标中, 假阴性 (FN) 被赋予最高的关注权重——一个被漏检的诈骗通话可能导致受害者遭受实际财产损失, 而假阳性 (FP) 的主要代价是用户需要多看一眼被拦截的通话, 两类错误的业务代价严重不对称。

6.2 方案一与方案二: 训练过程详细分析

6.2.1 逐 Epoch 性能演进

表 8 和表 9 分别列出了方案一 (提示词 +MLP) 和方案二 (ASR+MLP) 在 20 个训练 epoch 中的完整指标变化。

表 8: 方案一（提示词 +MLP）逐 Epoch 测试指标

Epoch	Test Loss	F1	Accuracy	FN	FP
1	0.2332	0.9022	0.9050	20	0
2	0.1315	0.9449	0.9475	11	0
3	0.0803	0.9666	0.9675	7	0
4	0.0379	0.9851	0.9850	3	0
5	0.0322	0.9850	0.9850	3	0
6	0.0670	0.9709	0.9725	6	0
7	0.0482	0.9822	0.9825	4	0
8	0.0495	0.9780	0.9775	5	0
9	0.0428	0.9873	0.9875	3	0
10	0.0189	0.9926	0.9925	1	0
11	0.0149	0.9925	0.9925	2	0
12	0.0183	0.9924	0.9925	2	0
13	0.0127	0.9975	0.9975	1	0
14	0.0113	0.9950	0.9950	1	0
15	0.0110	0.9975	0.9975	1	0
16	0.0089	1.0000	1.0000	0	0
17	0.0494	0.9796	0.9800	4	0
18	0.0084	0.9975	0.9975	1	0
19	0.0136	0.9901	0.9900	2	0
20	0.0071	0.9975	0.9975	1	0

表 9: 方案二（ASR+MLP）逐 Epoch 测试指标

Epoch	Test Loss	F1	Accuracy	FN	FP
1	0.0627	0.9664	0.9675	7	0
2	0.0406	0.9873	0.9875	3	0
3	0.0098	0.9950	0.9950	1	0
4	0.0081	0.9975	0.9975	1	0
5	0.0171	0.9950	0.9950	1	0
6	0.0060	0.9975	0.9975	1	0
7	0.0069	0.9975	0.9975	1	0
8	0.0067	0.9975	0.9975	1	0
9	0.0050	0.9975	0.9975	1	0
10	0.0119	0.9950	0.9950	1	0
11	0.0036	1.0000	1.0000	0	0
12	0.0046	1.0000	1.0000	0	0
13	0.0260	0.9899	0.9900	2	0
14	0.0064	0.9950	0.9950	1	0
15	0.0026	1.0000	1.0000	0	0
16	0.0084	0.9975	0.9975	1	0
17	0.0017	1.0000	1.0000	0	0
18	0.0028	1.0000	1.0000	0	0
19	0.0031	0.9975	0.9975	1	0
20	0.0020	1.0000	1.0000	0	0

从两张逐 epoch 表中可以观察到以下模式：

- (1) **收敛速度差异显著：**方案二在 epoch 1 即达到 F1=0.9664、FN=7，方案一 epoch 1 仅 F1=0.9022、FN=20——初始差距约 6.4 个 F1 百分点和 13 个漏检样本。这表明 ASR 转写文本从一开始就为模型提供了远更丰富的区分性语义信息；

- (2) **达到满分所需的训练量**：方案二在 epoch 11 首次达到 F1=1.0，耗时约 2.75 分钟（11/20 × 5 分钟）；方案一在 epoch 16 才首次达到满分，耗时约 4 分钟。5 个 epoch 的差距在更大规模数据集上将被显著放大；
- (3) **满分的稳定性**：方案二在 20 个 epoch 中有 6 个 epoch（11/12/15/17/18/20）达到 F1=1.0，占 30%；方案一仅 1 个 epoch（16），占 5%。ASR 方案不仅更快到达满分，而且更频繁地回到满分状态，其学习到的决策边界在参数空间中位于一个更宽的”完美区域”；
- (4) **所有 epoch 均保持 FP=0**：两个方案的假阳性在所有 20 个 epoch 中始终为零。这意味着模型从未将任何正常通话误判为诈骗。结合训练集中正负样本均衡（约 1:1）的事实，FP=0 不是”模型偏向预测 normal”的产物，而是模型确实学会了准确区分两个类别的证据。

6.3 方案三：端到端训练过程分析

表 10 列出了方案三（E2E Unfreeze）在 10 个 epoch 中的逐 epoch 指标。

表 10: 方案三（E2E Unfreeze）逐 Epoch 测试指标

Epoch	Test Loss	F1	Accuracy	FN	FP
1	0.1148	0.9637	0.9650	7	0
2	0.0697	0.9771	0.9775	5	0
3	0.0326	0.9875	0.9875	3	0
4	0.0163	0.9950	0.9950	2	0
5	0.0285	0.9924	0.9925	3	0
6	0.0240	0.9924	0.9925	3	0
7	0.0339	0.9924	0.9925	3	0
8	0.0176	0.9924	0.9925	3	0
9	0.0298	0.9924	0.9925	3	0
10	0.0215	0.9924	0.9925	3	0

方案三的指标轨迹呈现明显的”早熟”特征：F1 在 epoch 4 达到峰值 0.9950（2 FN, 0 FP）后，epoch 5–10 统一停留在 0.9924（3 FN, 0 FP），而训练损失继续从 0.0163 在后续 epoch 出现波动（回升至 0.0285、0.0339 等），这一模式是典型的小批量过拟合信号——

模型在训练集上继续优化（损失波动但整体极低，训练损失在 epoch 10 已降至 2.48×10^{-5} ），但测试指标不再提升，说明模型在有限的 4000 条训练样本上已耗尽泛化能力。等效 batch size=8 的梯度估计噪声可能进一步加剧了这一现象，因为每个优化步仅基于 1 条样本的梯度方向，8 步累积后仍无法达到大批量下的梯度平滑效果。

6.4 四种方案最佳指标综合对比

表 11: 四种方案最佳 epoch 指标汇总对比

方案	最佳 Epoch	F1	Acc	Prec	Rec	FN	FP	大小	训练时间
提示词 +MLP	16	1.000	1.000	1.000	1.000	0	0	1.6 MB	~5 min
ASR+MLP	11	1.000	1.000	1.000	1.000	0	0	1.6 MB	~5 min
E2E Unfreeze	4	0.995	0.995	1.000	0.990	2	0	338 MB	~3 h
SFT LoRA	3	0.993	0.990	1.000	0.986	2	0	35 MB	~6.5 h

6.5 训练曲线可视化




图 6: 三种训练方案的测试损失收敛曲线对比

图 6 以折线图形式对比了三种方案的测试损失随 epoch 的变化趋势。核心观察：(1) ASR 方案（橙色）的损失曲线始终位于提示词方案（蓝色）下方，说明 ASR 转写在全阶段均提供了更强的监督信号；(2) E2E 方案（绿色）的损失曲线在 epoch 4 后出现拐点——测试损失不再单调下降，转而呈现波动甚至回升，这与其 F1 在 epoch 4 达到峰值即不再改善的趋势高度吻合；(3) 提示词方案的损失曲线虽然初始值最高（epoch 1 = 0.33），但下降趋势清晰，最终在 epoch 16–20 区间接近 ASR 方案的水平。




图 7: F1 分数进化曲线，散点标注各方案最佳 epoch

图 7 以相同坐标尺度展示了 F1 分数随训练 epoch 的演化轨迹。方案二的 F1 曲线始终处于最高位置，且在 epoch 11 后的多个 epoch 反复触及 F1=1.0 的上限，表明其在参数空间中找到了一个宽泛且鲁棒的“完美区域”。方案一的 F1 曲线在 epoch 1–10 期间缓慢爬升，epoch 13–20 期间在高位剧烈波动（0.9796–1.0000），表明其决策边界在完美区域边缘振荡，稳定性不如方案二。方案三的 F1 曲线在 epoch 4 触顶后即进入平台期，反映了小批量端到端训练的性能天花板。

6.6 多维度指标可视化与综合讨论




图 8: 四种方案在 Accuracy、Precision、Recall、F1 四个维度上的分组柱状图对比

图 8 以分组柱状图形式并列展示了四种方案在四个核心指标上的得分。一个突出的视觉特征是：Precision 柱在所有方案中均为 1.000（蓝色柱始终触顶），而 Recall 柱的微小差异（ASR/提示词 1.000 vs E2E 0.990 vs SFT 0.986）直接决定了 F1 的差值。这表明所有方案的分类边界都极度保守——模型倾向于仅在高置信度下才输出“fraud”标签，从而以牺牲少量召回为代价（在 E2E 和 SFT 方案中分别牺牲了 2 个样本），换取了零误报的严格约束。




图 9: 模型大小-F1 散点图，气泡面积正比于训练时间

图 9 以气泡图形式将模型规模（x 轴，对数坐标）、检测精度（y 轴，F1 分数）和训练成本（气泡面积）三个维度同时编码在一张图中。该图最核心的信息在于”规模不经济”（diseconomies of scale）的可视化呈现：E2E 方案以 338 MB 的模型体积（ASR+MLP 方案的 211 倍）和约 3 小时的训练时间（ASR+MLP 方案的 36 倍），仅换来了 F1 降低 0.005 的结果。SFT LoRA 方案以 35 MB（22 倍）

和约 6.5 小时（78 倍），获得了 $F1=0.993$ 以及可解释检测理由的独特能力——其价值无法仅用 F1 衡量。

从部署工程的角度审视，ASR+MLP 方案以 1.6 MB 体积和 5 分钟训练达到 $F1=1.000$ ，在所有维度上均为 Pareto 最优。但这并不意味着 E2E 和 SFT 方案没有价值：它们分别验证了音频特征任务适配的可行性和大模型可解释检测的潜力，为未来在更大规模数据和更强硬件条件下的优化提供了实证基础和方法论参考。

6.7 混淆矩阵




图 10: 四种方案的混淆矩阵（2×2 热力图，测试集 400 样本）

图 10 以 2×2 热力图形式展示了四种方案的混淆矩阵。共同的视觉特征：所有四个矩阵的右上角（Pred Normal, True Fraud ——即 FN）和左上角到右下角的对角线之外均为极低值或零。方案一和方案二的混淆矩阵是完全的对角矩阵（TN=200, TP=200, FP=0, FN=0），方案三和方案四仅在 FN 格有非零值（2），FP 格均为零。16 个混淆矩阵单元格中，14 个呈现“完美”或“接近完美”的状态，这在 400 条真实世界音频测试集上是非常强的表现。

6.8 SFT LoRA 训练与数据详情




图 11: SFT LoRA 训练损失下降与 epoch 3 评估指标

图 11 以双 y 轴图展示了 SFT LoRA 训练过程中的损失下降（左轴，红色折线）和 epoch 3 评估时的 F1 指标（右轴，蓝色菱形标记）。训练损失从 epoch 1 的 0.897 经 epoch 2 的 0.686 最终降至 epoch 3 的 0.553，下降幅度达 38.4%，表明模型在 27k 指令样本上有效学习。epoch 3 在 200 条测试样本上的评估结果为 F1=0.993、Accuracy=99.0%、FP=0、FN=2。

训练损失的下降速度在 epoch 1 → 2 期间最快 ($\Delta\text{loss} = 0.211$)，epoch 2 → 3 趋缓 ($\Delta\text{loss} = 0.133$)，暗示 4-5 个 epoch 的训练可能进一步降低损失并缩小与 MLP 方案的 F1 差距。然而，更长的训练也伴随着更大的过拟合风险（尤其在类别不平衡的 SFT 数据上），需要在未来工作中通过验证集早停策略进行控制。




图 12: SFT 数据集组成：任务模式分布（左饼图）与 FRAUD_BINARY 子集的标签分布（右饼图）

图 12 以双饼图展示了 SFT 数据的内部构成。左图显示 FRAUD_BINARY（二分类）和 SCENE_ONLY（场景识别）各占 39.5%，FRAUD_TYPE（诈骗类型）占 21.1%，三种任务模式共同构成指令微调的多任务混合。右图聚焦 FRAUD_BINARY 子集的标签分布：fraud 占 69.7%，normal 占 30.3%，呈现

约 2.3:1 的类别不均衡。这一不均衡可能导致模型在训练中对 fraud 样本的拟合优于 normal 样本，是未来需要通过重采样或加权损失函数改进的方向之一。

7 讨论

7.1 为什么 ASR 转写如此关键？

实验中最显著的模式是：ASR 转写文本相对于提示词文本带来了约 5 个 epoch 的收敛加速和更稳定的满分复现。这一现象的解释可以从信息论的角度来理解：

提示词文本对模型提供的仅是“这是一个二分类任务”的先验信息——所有 4000 条训练样本共享几乎相同的提示词，因此文本分支的输出在样本间几乎没有方差，无法提供区分性特征。而 ASR 转写文本直接包含了通话的语义内容——是否出现“转账”“安全账户”“验证码”等诈骗标志词、说话人的语气模式（通过转写文本中的标点和措辞间接体现）、对话的结构特征（如是否存在威逼利诱的对话结构）等。这些语义信息与音频嵌入中的声学线索形成互补，共同支撑了高精度分类。

7.2 端到端训练何时值得？

方案三的结果引出了一个重要的方法论问题：在什么条件下，端到端训练能够超越离线特征缓存方案？

基于本研究的实验证据，我们认为以下条件有助于端到端训练发挥优势：(1) 训练数据量足够大（至少数万条），能够支撑 14.6M 可训练参数而不严重过拟合；(2) 物理 batch size 能够达到 8–16 以上（配合梯度累积达到等效 batch 32+），减少梯度估计噪声；(3) 音频特征的任务适配需求确实存在——如果冻结编码器已经提取了足够的区分性信息（如本数据集中 ASR+MLP 即达 $F1=1.0$ ），则端到端训练的边际收益为负；(4) 学习率需要更系统的搜索（如对 encoder 层使用网格搜索 10^{-6} – 10^{-4} ）。

在当前数据规模和硬件条件下，端到端训练相对于离线缓存方案是“规模不经济”的，但这一结论不应被泛化为“端到端训练总是更差”。随着数据规模和 GPU 显存的增长，端到端方案的有效 batch size 和可训练层数都有提升空间，其性能差距有望缩小甚至逆转。

7.3 SFT LoRA 的定位与价值

SFT LoRA 方案在 F1 上略逊于 MLP 方案（0.993 vs 1.000），但其核心价值不在判别精度的提升，而在于输出模态的质变——从一个不可解释的二分类标签变为包含判断理由的结构化 JSON 报告。在以下场景中，这一质变具有决定性意义：

- **监管合规：**金融监管机构可能要求自动化检测系统提供可审计的决策依据，“模型说是诈骗”不构成合规证据，而“模型检测到‘安全账户’‘转账’等关键词并结合恐吓性话术”则构成可验证的决策记录；
- **人工复核效率：**审核员面对每天数千条被标记的通话，如果每条都需要从头听取音频，效率极低；而如果每条附带 20–50 字的 AI 判断理由，审核员可以快速筛选出真正需要关注的样本；
- **用户信任：**被拦截通话的用户可能质疑系统的判断，一个附带理由的检测结论（如“您的通话中提到了‘安全账户’这一常见诈骗话术”）比一个简单的“此通话为诈骗”标签更可能获得用户的理解和信任。

因此，在部署策略上，我们推荐将方案二（ASR+MLP）作为第一级快速筛选器，对低置信度样本（概率 0.5–0.7 区间，在方案二中极少出现）自动触发方案四（SFT LoRA）的二次检测并生成可解释报告，形成“速度优先 + 可解释兜底”的两级检测架构。

7.4 研究的局限性

本研究存在以下主要局限性，需要在解读结论时予以考虑：

- (1) **数据集规模与多样性：**二分类训练集仅 4000 条，来自单一数据源。在更大规模（数万至数十万条）和更多来源（不同地区、不同诈骗类型、不同录音环境）的数据上，各方案的相对排序可能发生变化；
- (2) **测试集规模：**400 条测试样本中， $F1=1.0$ vs 0.995 的差异仅取决于 0 vs 2 个样本的误判。这一差异在统计上可能不显著，更大队列的测试集有助于更可靠地分辨方案间的细微性能差异；

- (3) **超参数搜索范围**: MLP 方案使用了单一的超参数组合 ($lr=1e-3$, $hidden=256$, $dropout=0.2$); E2E 方案的分层学习率 ($5e-5 / 5e-6$) 是经验设定。更系统的超参数搜索可能进一步改善各方案的指标;
- (4) **硬件约束**: 所有实验在单张 RTX 3060 Laptop GPU (6 GB) 上完成。方案三和方案四的训练设置 ($batch=1$, $grad_accum=8$) 是对显存约束的妥协, 在更大显存的硬件上可探索更大 batch size 和更高的训练效率。

8 模型优化展望

基于上述实验结果和讨论, 本节从数据、模型、部署和可解释性四个维度展望未来的优化方向。

8.1 数据层面

- (1) **数据增强**: 在音频层面, 可通过变速 (0.9–1.1 倍速)、添加背景噪声 (白噪声/街道噪声/办公室噪声)、音调变换 (pitch shifting) 等方式增加训练数据的声学多样性, 提升模型对不同录音环境和说话人特征的鲁棒性。在文本层面, 可通过同义词替换、回译 (中 $\rightarrow$ 英 $\rightarrow$ 中) 等方式生成语义等价但措辞不同的训练样本;
- (2) **类别平衡策略**: SFT 数据中 fraud/normal 比例约 7:3 的不平衡可通过以下策略缓解: (a) 对少数类 (normal) 进行过采样或对多数类 (fraud) 进行欠采样; (b) 在损失函数中引入类别权重, 提高 normal 样本误判的惩罚系数; (c) 在数据加载阶段使用 WeightedRandomSampler 确保每个 batch 内的类别比例接近 1:1;
- (3) **跨领域数据引入**: 当前数据集集中于冒充官方机构和账户风险两类诈骗。未来可引入投资理财诈骗、情感诈骗 (杀猪盘)、冒充熟人诈骗、虚假征信诈骗等更多元化的诈骗类型, 增强模型的泛化边界和实用性。

8.2 模型层面

- (1) **升级 ASR 引擎**: 当前 Whisper-small (88.2M) 的中文转写错误率 (CER) 在清晰录音上约 5–8%, 在嘈杂环境或方言口音下可能升至 15–20%。升级至 Whisper-medium (769M, CER 降低约 30–40%) 或 Whisper-large-v3 (1.5B), 可显著降低转写错误对下游分类的噪声干扰;
- (2) **原生音频大语言模型**: 当前级联架构 (ASR $\rightarrow$ LLM) 存在一个结构性局限——转写错误会向下游传播且不可恢复。使用 Qwen2-Audio、SALMONN 或 Gemini-1.5-Flash 等原生支持音频输入的大模型, 可跳过独立的 ASR 步骤, 直接在音频 token 上进行推理, 从根本上消除“转写错误传导”这一级联瓶颈;
- (3) **多任务联合学习**: 在 SFT LoRA 框架下, 可同时训练欺诈检测 (二分类)、诈骗类型分类 (多分类: 冒充公检法/贷款诈骗/投资诈骗/...) 和风险等级评估 (有序回归) 三个相关任务, 通过任务间的共享表示学习提升各任务的泛化性能;
- (4) **对比学习预训练**: 在 MLP 融合训练前, 可先使用 SimCLR 或 SupCon 等对比学习框架, 在嵌入空间中拉近同类别 (fraud–fraud 和 normal–normal) 音频–文本对的表示距离、推远不同类别对的表示距离, 增强特征空间的线性可分性。

8.3 部署与工程层面

- (1) **模型量化与蒸馏**: 1.6 MB 的 MLP 模型可进一步通过 INT8 量化压缩至约 0.4 MB, 推理速度提升 2–3 倍且精度损失可忽略。338 MB 的 E2E 模型和 35 MB 的 SFT LoRA adapter 可通过知识蒸馏 (以 F1=1.0 的 MLP 模型为 teacher) 压缩为更小的 student 模型;
- (2) **流式推理架构**: 当前推理为离线批量模式。在实际部署中, 通话是实时进行的, 需要将推理流水线改造为流式处理: 每积累 N 秒音频 (如 5 秒) 即触发一次增量 ASR 转写和分类推理, 在通话进行中动态更新检测结果和风险等级;
- (3) **终端侧部署**: Whisper.cpp 项目 [?] 已在移动端和嵌入式设备上实现了高效的 Whisper 推理。结合本文 1.6 MB 的 MLP 分类器, 可以构建完全离线的手机端电诈检测应用——在通话过程中实时转写和检测, 无需将音频上传至云端, 兼顾隐私保护和低延迟;

- (4) **人在回路**：对于模型输出概率落在不确定区间（如 0.5–0.7）的样本，自动转交人工审核平台。审核员的标签反馈可作为新的训练数据持续优化模型，形成“检测—审核—反馈—更新”的数据飞轮。

8.4 可解释性增强

- (1) **注意力可视化**：利用 Transformer 的注意力权重矩阵，可视化模型在处理通话文本时对哪些 token（词或字）分配了最高的注意力权重。如果模型在“转账”“安全账户”“验证码”等关键词上的注意力显著高于其他词，则为模型的判断提供了直观的解释；
- (2) **细粒度证据链**：在 SFT 模型的指令模板中要求输出更详细的证据链——不仅标注检测到的诈骗关键词，还要标注其在通话文本中的具体位置（字符偏移量）和属于何种诈骗类型（如“冒充公检法—安全账户话术”），使检测报告达到可独立审计的质量标准。

9 结论

本文面向中文电话录音场景下的多模态电诈检测任务，在消费级 GPU（RTX 3060 Laptop, 6 GB）的硬件约束下，系统性地设计、实现并对比了四条复杂度递增的技术路线。在包含 4000 条训练样本和 400 条测试样本的二分类数据集上，四条路线的最佳性能如下：

- (1) **提示词 + 冻结编码器 + MLP（基线方案）**：F1=1.000, Accuracy=1.000, FN=0, FP=0, 模型 1.6 MB, 训练 ~5 min；
- (2) **ASR 转写 + 冻结编码器 + MLP（推荐部署方案）**：F1=1.000, Accuracy=1.000, FN=0, FP=0, 模型 1.6 MB, 训练 ~5 min——收敛速度比方案一快 5 个 epoch，满分复现频率高 6 倍；
- (3) **端到端部分解冻（探索性方案）**：F1=0.995, Accuracy=0.995, FN=2, FP=0, 模型 338 MB, 训练 ~3 h——在小批量约束下验证了音频特征任务适配的可行性；
- (4) **SFT LoRA 指令微调（可解释方案）**：F1=0.993, Accuracy=0.990, FN=2, FP=0, Adapter 35 MB, 训练 ~6.5 h——具备生成检测理由和置信度评分的独特能力。

基于上述实验结果，我们得出以下核心结论：

- ASR 语音转写是提升模型性能最关键的单因素——将文本输入从人工提示词替换为 Whisper 自动转写的通话语义文本，可在保持零假阳性的前提下，将收敛速度提升约 33%（提前 5 个 epoch 达 F1=1.0），并将满分 epoch 的复现率从 5% 提升至 30%；
- 轻量级 MLP 融合分类器在 400 条平衡测试集上实现了零假阳性、零假阴性的完美检测——这是一个很强的实用结果，意味着在训练数据分布内的测试场景中，该方案可以完全避免对正常通话的误判（保护用户体验）和对诈骗通话的漏判（保护用户财产安全）；
- 四项方案的一致特征——FP=0——表明模型学到的决策边界在所有方案中都高度保守，倾向于仅在高置信度下输出 fraud 标签。这一特性在电诈检测这一“宁可漏判、不可误判”（需注意此处“漏判”指诈骗被漏，代价极高，因此实际业务偏好是“宁可误报、不可漏报”，但我们的模型同时实现了 FP=0 和极低 FN）或更准确地说“在保持零误报的前提下最小化漏报”的业务需求下尤为可贵；
- 综合考量检测精度、模型部署体积、训练时间成本和可解释性四个维度，**ASR 转写 + 冻结编码器 + MLP 融合分类器（方案二）**被确定为当前条件下的推荐部署方案。该方案以 1.6 MB 的极小模型体积（可通过电子邮件附件传输）、约 5 分钟的训练时间（支持快速迭代更新）、以及 F1=1.000 的完美检测性能，在工程部署的便捷性与检测的可靠性之间取得了最佳平衡。

此外，本研究构建的 Web 演示工作台（支持预置样例、音频上传和文本输入三种检测模式）和 SFT LoRA 指令微调流水线（生成结构化可解释检测报告），为模型在课程答辩中的现场展示和面向实际应用的后续演进提供了完整的前后端代码基础和可复现的训练-评估流程。